

AI Course

Capstone Project Final Report

DỰ ÁN: HỆ THỐNG PHÁT HIỆN TẾ NGÃ CHO NGƯỜI GIÀ

©2025 SAMSUNG. All rights reserved.

Samsung Electronics Corporate Citizenship Office holds the copyright of this document.

This document is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.

To use this document other than the curriculum of Samsung Innovation Campus, you must receive written consent from copyright holder.

DỰ ÁN: HỆ THỐNG PHÁT HIỆN TẾ NGÃ CHO NGƯỜI GIÀ

25/08/2026

Team Name: GUARDIAN

1. Phạm Long Chúc – DTC235220004
2. Trần Thị Hào – DTC235200252
3. Nguyễn Xuân Linh – DTC235200452
4. Trần Đức Mạnh – DTC235220026

LỜI CẢM ƠN

Nhóm chúng em xin chân thành cảm ơn **Samsung Innovation Campus** và các giảng viên đã tận tình hướng dẫn, hỗ trợ và cung cấp những kiến thức cần thiết trong suốt quá trình học tập và thực hiện **AI Course – Capstone Project**.

Thông qua dự án “**HỆ THỐNG PHÁT HIỆN TẾ NGÃ CHO NGƯỜI GIÀ**”, nhóm có cơ hội vận dụng những kiến thức về Trí tuệ nhân tạo, Học sâu và Thị giác máy tính vào một bài toán thực tế. Trong quá trình thực hiện, nhóm đã tích lũy thêm nhiều kinh nghiệm về xử lý dữ liệu, xây dựng và đánh giá mô hình AI cũng như phát triển hệ thống.

Do thời gian và kinh nghiệm còn hạn chế, dự án không tránh khỏi những thiếu sót. Nhóm chúng em rất mong nhận được những ý kiến đóng góp từ giảng viên để hoàn thiện dự án tốt hơn.

Nhóm chúng em xin chân thành cảm ơn!

NỘI DUNG

LỜI CẢM ƠN.....	3
NỘI DUNG.....	4
DANH MỤC HÌNH ẢNH.....	6
DANH MỤC BẢNG BIỂU.....	7
1. GIỚI THIỆU.....	8
1.1. Thông tin nền.....	8
1.1.1 Bối cảnh nghiên cứu.....	8
1.1.2 Xu hướng ứng dụng trí tuệ nhân tạo trong phát hiện té ngã.....	9
1.1.3 Giới thiệu đề tài.....	10
1.1.4 Phát biểu bài toán.....	11
1.2. Động lực và mục tiêu nghiên cứu.....	13
1.2.1. Động lực.....	13
1.2.2. Mục tiêu dự án.....	13
1.3. Phạm vi đề tài.....	14
1.4. Nhân sự và Phân công nhiệm vụ.....	15
1.5. Kế hoạch và Các mốc tiến độ.....	17
2. TRIỂN KHAI ĐỀ TÀI.....	20
2.1. Thu thập dữ liệu.....	20
2.1.1. Giới thiệu bộ dữ liệu.....	20
2.1.2 Đặc điểm và thống kê dữ liệu.....	20
2.1.3. Chiến lược phân chia dữ liệu.....	21
2.2. Tiền xử lý dữ liệu.....	22
2.2.1. Đọc video và Bóc tách nhãn Annotation.....	22
2.2.2. Trích xuất điểm khớp cơ thể (Keypoint Extraction).....	23
2.2.3. Chuẩn hóa Không gian Khung xương (Spatial Normalization).....	24
2.2.4. Trích xuất đặc trưng động học (Kinematic Feature Engineering).....	25
2.2.5. Tạo chuỗi dữ liệu bằng Sliding Window.....	25
2.2.6. Tăng cường dữ liệu.....	26
2.2.7. Kết quả sau tiền xử lý.....	27
2.3. Phương pháp huấn luyện.....	27
2.3.1. Các mô hình được khảo sát.....	27

2.3.2. BiGRU kết hợp cơ chế chú ý Feed-Forward Soft Attention.....	29
3. KẾT QUẢ THỰC NGHIỆM.....	32
3.1. Tối ưu hóa siêu tham số mô hình (Grid Search).....	32
3.2. Khảo sát ma trận siêu tham số Focal Loss ($\alpha \times \gamma$).....	33
3.2.1. Ma trận kết quả trên các kiến trúc mô hình	33
3.2.2. Phân tích kết quả định lượng và luận điểm lựa chọn.....	35
3.3. Đánh giá đóng góp của từng thành phần (Ablation Study)	36
3.4. Đánh giá hiệu năng trên tập Test độc lập và Ma trận nhầm lẫn.....	38
3.4.1. Chỉ số hiệu năng tổng quát	39
3.4.2. Phân tích Ma trận nhầm lẫn (Confusion Matrix Analysis)	39
3.5. Phân tích quá trình huấn luyện (Loss & Accuracy History).....	40
3.5.1. Phân tích diễn biến Loss (Loss History).....	40
3.5.2. Phân tích diễn biến Độ chính xác (Accuracy History)	41
3.6. Giao diện người dùng	41
3.6.1. Kiến trúc và Nguyên lý vận hành Client-Server.....	42
3.6.2. Các khối chức năng chính trên Dashboard	42
4. ĐÁNH GIÁ TÁC ĐỘNG VÀ ĐỊNH HƯỚNG PHÁT TRIỂN.....	43
4.1. Kết quả đạt được và Giá trị của ứng dụng.....	43
4.1.1. Kết quả đạt được	43
4.1.2. Giá trị ứng dụng của hệ thống.....	43
4.2. Hạn chế của đề tài.....	44
4.3. Hướng phát triển trong tương lai	44
KẾT LUẬN	46
DANH MỤC THAM KHẢO	47
NHẬN XÉT VÀ ĐÁNH GIÁ CỦA CÁC THÀNH VIÊN.....	48
NHẬN XÉT VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN HƯỚNG DẪN.....	49

DANH MỤC HÌNH ẢNH

Hình 1. 1. Minh họa chuỗi chuyển biến tư thế khung xương trong quá trình di chuyển và té ngã.....	9
Hình 1. 2. Mô hình hóa cấu trúc Tensor 102 chiều đặc trưng động học cho mỗi khung hình.	12
Hình 1. 3. Sơ đồ luồng xử lý dữ liệu tổng thể từ video đầu vào đến kết quả dự đoán của hệ thống.....	12
Hình 2. 1. Sơ đồ mô tả quy trình chuẩn hóa không gian dời gốc tọa độ về tâm hông.	24
Hình 2. 2. Mô hình hóa cấu trúc Tensor 102 chiều đặc trưng động học cho mỗi khung hình.	25
Hình 2. 3. Sơ đồ nguyên lý phân cụm chuỗi thời gian bằng kỹ thuật cửa sổ trượt (Sliding Window).	26
Hình 2. 4. Sơ đồ luồng quy trình tiền xử lý dữ liệu từ video thô sang chuỗi tensor khung xương.	27
Hình 2. 5. Sơ đồ tính toán cơ chế chú ý Feed-Forward Soft Attention và tạo lập vector ngữ cảnh c	30
Hình 3. 1. Ma trận nhầm lẫn chuẩn hóa (Normalized Confusion Matrix) của mô hình BiGRU-Attention.....	39
Hình 3. 2. Biểu đồ lịch sử huấn luyện Loss (trái) và Accuracy (phải) của mô hình BiGRU-Attention.....	40
Hình 3. 3. Giao diện Dashboard giám sát thời gian thực khi hệ thống phát hiện sự cố té ngã.....	42

DANH MỤC BẢNG BIỂU

Bảng 1. 1. Phân công công việc của các thành viên.....	16
Bảng 1. 2. Kế hoạch thực hiện và các mốc chính.....	18
Bảng 2. 1. Thống kê bộ dữ liệu.	21
Bảng 2. 2. Phân chia chi tiết bộ dữ liệu Train – Validation – Test.....	22
Bảng 2. 3. So sánh hiệu năng 4 kiến trúc (5-Fold Cross Validation).....	28
Bảng 3. 1. Kết quả tối ưu hóa siêu tham số mô hình BiGRU-Attention bằng Grid Search.	32
Bảng 3. 2. Ma trận khảo sát siêu tham số Focal Loss ($\gamma \times \alpha$) trên mô hình BiGRU-Attention (Val F1 %).	34
Bảng 3. 3. Ma trận khảo sát siêu tham số Focal Loss ($\gamma \times \alpha$) trên mô hình LSTM (Val F1 %).	34
Bảng 3. 4. Ma trận khảo sát siêu tham số Focal Loss ($\gamma \times \alpha$) trên mô hình GRU (Val F1 %).	34
Bảng 3. 5. Ma trận khảo sát siêu tham số Focal Loss ($\gamma \times \alpha$) trên mô hình CNN-1D (Val F1 %).	35
Bảng 3. 6. Kết quả thực nghiệm nghiên cứu bóc tách thành phần (Ablation Study) trên tập Validation.	36
Bảng 3. 7. Hiệu năng mô hình BiGRU-Attention trên tập Test độc lập.	39

1. GIỚI THIỆU

1.1. Thông tin nền

1.1.1 Bối cảnh nghiên cứu

Ngày nay, tỉ lệ người bị đột quỵ và tỉ lệ già hóa đang ngày càng tăng cao đã làm tăng nguy cơ té ngã. Theo nghiên cứu được thực hiện bởi Trung tâm Kiểm soát và Phòng ngừa dịch bệnh (CDCP), khoảng 36 triệu ca té ngã được báo cáo mỗi năm dẫn đến 32,000 ca tử vong¹. Tại Việt Nam, nghiên cứu lâm sàng tại Bệnh viện Lão khoa Trung ương ghi nhận tỷ lệ té ngã ở người cao tuổi lên tới 23,7%, trong đó 65,6% các ca té ngã gây ra chấn thương thể chất và gần 70% sự cố xảy ra ngay tại không gian sinh hoạt gia đình². Do đó, việc nghiên cứu và triển khai hệ thống tự động phát hiện té ngã là nhu cầu cấp thiết nhằm giảm thiểu rủi ro sức khỏe và hỗ trợ can thiệp y tế kịp thời.

Để giải quyết vấn đề này, nhiều phương pháp giám sát được phát triển, phổ biến là các thiết bị cảm biến đeo trên người hoặc hệ thống camera RGB giám sát trực tiếp. Tuy nhiên, thiết bị đeo thường gây ra sự bất tiện do người già dễ quên sử dụng, thời lượng pin giới hạn và thường tạo ra cảnh báo giả khi người dùng thực hiện các hoạt động hàng ngày³. Trong khi đó, camera giám sát RGB thông thường lại xâm phạm nghiêm trọng đến không gian sống riêng tư, có thể gây ra cảm giác lo âu, bất lực hay bị kiểm soát, làm xói mòn lòng tự trọng và quyền tự chủ của người cao tuổi⁴.


Do đó, phương pháp phân tích dựa trên khung xương (skeleton-based) đã nổi lên như một hướng tiếp cận tối ưu giúp bảo vệ quyền riêng tư bằng cách chỉ xử lý tọa độ chuyển động của các khớp xương thay vì lưu trữ luồng video thô, vừa đảm bảo tính chính xác vừa giảm thiểu độ phức tạp tính toán.

¹ [1] Moreland, B. a. Kakara, R. a. Henry, and Aim, "Trends in Nonfatal Falls and Fall-Related Injuries Among Adults Aged," *MMWR. Morbidity and Mortality Weekly Report*, vol. 69, pp. 875--881, 2020. [Online]. Available: <https://www.cdc.gov/mmwr/volumes/69/wr/mm6927a5.htm>.

² [2] V. T. Ha *et al.*, "Prevalence and Factors Associated with Falls among Older Outpatients," (in eng), *Int J Environ Res Public Health*, vol. 18, no. 8, Apr 12 2021, doi: 10.3390/ijerph18084041.

³ [3] R. Igual, C. Medrano, and I. Plaza, "Challenges, issues and trends in fall detection systems," *BioMedical Engineering OnLine*, vol. 12, no. 1, p. 66, 2013/07/06 2013, doi: 10.1186/1475-925X-12-66.

⁴ [4] Tan-in, T. a. Tangsakul, S. a. Namburi, and Atchara, "Edge-Native Privacy-Preserving Fall Detection System Using Optimized Skeleton-Based Pose Estimation on NVIDIA Jetson," *Department of Computer and Information Science, Faculty of Science and Engineering, Kasetsart University*, 2026.



Hình 1. 1. Minh họa chuỗi chuyển biến tư thế khung xương trong quá trình đi chuyển và té ngã.

1.1.2. Xu hướng ứng dụng trí tuệ nhân tạo trong phát hiện té ngã

Sự phát triển mạnh mẽ của Trí tuệ nhân tạo, Học sâu và Thị giác máy tính đã định hình những xu hướng tiếp cận công nghệ mang tính đột phá trong bài toán phân tích hành vi con người.

Trước hết, xu hướng công nghệ chuyển dịch rõ rệt từ việc phân tích hình ảnh màu RGB sang biểu diễn khung xương. Việc trích xuất các điểm khớp giải phẫu học giúp hệ thống tập trung hoàn toàn vào đặc trưng tư thế và hình thái chuyển động cốt lõi, loại bỏ hoàn toàn các yếu tố nhiễu do phong nền, điều kiện ánh sáng hay màu sắc trang phục, đồng thời giải quyết triệt để bài toán bảo vệ quyền riêng tư cá nhân khi không lưu trữ hình ảnh khuôn mặt⁵. Bên cạnh đó, do hành vi té ngã mang bản chất là quá trình biến thiên năng lượng và tư thế đột ngột, việc kết hợp giữa tọa độ vị trí tĩnh cùng các đạo hàm động học theo thời gian bao gồm vận tốc và gia tốc cung cấp nguồn thông tin toàn diện về động lực học của sự cố⁶.

Về mặt mô hình hóa, các kiến trúc mạng hồi quy hai chiều BiGRU cho phép tiếp cận đồng thời cả ngữ cảnh chuyển động từ quá khứ đến tương lai trong một cửa sổ trượt⁷. Khi tích hợp cơ chế chú ý Soft Attention, mô hình có khả năng tự động tập trung trọng số vào các pha mất thăng bằng then chốt trong chuỗi hành vi⁸. Đồng thời,

⁵ [5] C.-I. Wang and J. Yan, "A Comprehensive Survey of RGB-Based and Skeleton-Based Human Action Recognition," *IEEE Access*, vol. 11, pp. 53880-53898, 2023.

⁶ [6] W. Chen, Z. Jiang, H. Guo, and X. Ni, "Fall Detection Based on Key Points of Human-Skeleton Using OpenPose," *Symmetry*, vol. 12, no. 5, p. 744, 2020. [Online]. Available: <https://www.mdpi.com/2073-8994/12/5/744>.

⁷ [7] M. Schuster and K. K. Paliwal, "Bidirectional recurrent neural networks," *IEEE Transactions on Signal Processing*, vol. 45, pp. 2673-2681, 12/01 1997, doi: 10.1109/78.650093.

⁸ [8] C. R. a. D. P. W. Ellis, "Feed-Forward Networks with Attention Can Solve Some Long-Term

xu hướng thiết kế mô hình hiện nay hướng tới việc tối ưu hóa độ phức tạp tính toán nhằm đảm bảo khả năng suy luận thời gian thực với độ trễ thấp trên các thiết bị giám sát nhúng tại chỗ.

Từ các xu hướng công nghệ nêu trên, đề tài hướng giải pháp tích hợp luồng xử lý khép kín: trích xuất tư thế thời gian thực bằng YOLOv8n-Pose, chuẩn hóa không gian và sinh 102 chiều đặc trưng động học, kết hợp mạng BiGRU tích hợp Feed-Forward Soft Attention và tối ưu hóa phân lớp bằng Focal Loss nhằm xây dựng hệ thống phát hiện té ngã đạt độ tin cậy cao.

1.1.3. Giới thiệu đề tài

Đề tài “Hệ thống phát hiện té ngã cho người già” được triển khai nhằm nghiên cứu, phát triển và thực nghiệm một giải pháp công nghệ hoàn chỉnh hỗ trợ nhận diện tự động và chuẩn xác hành vi té ngã từ luồng video thời gian thực⁹.

Nội dung nghiên cứu của đề tài tập trung vào các trục cột kỹ thuật trọng tâm. Về dữ liệu, đề tài thực hiện phân loại nhị phân giữa hai nhóm hành vi Fall (sự cố té ngã) và ADL (hoạt động sinh hoạt hằng ngày bình thường) dựa trên tập dữ liệu chuẩn IMVIA Le2i Fall Detection Dataset thu thập tại bốn bối cảnh thực tế khác nhau. Để bảo tồn quyền riêng tư, hệ thống ứng dụng mô hình YOLOv8n-Pose nhằm trích xuất tọa độ không gian của 17 điểm khớp cơ thể từ khung hình video thô. Tọa độ khung xương sau khi được chuẩn hóa không gian về tâm hông và tỷ lệ chiều cao sẽ được biến đổi thành bộ vector 102 chiều đặc trưng động học biểu diễn vị trí, vận tốc và gia tốc theo chuỗi thời gian.

Ở khâu mô hình hóa, mạng nơ-ron hồi quy hai chiều BiGRU kết hợp cơ chế chú ý Feed-Forward Soft Attention được thiết lập nhằm khai thác sâu các mối liên hệ phụ thuộc thời gian và cô đọng vector ngữ cảnh mang biến thiên năng lượng đột ngột. Đi kèm với đó, hàm mất mát Focal Loss và kỹ thuật Skeleton Jittering được tích hợp để giải quyết triệt để hiện tượng mất cân bằng lớp. Cuối cùng, hiệu năng hệ thống được đánh giá định lượng toàn diện qua kiểm thử 5-Fold Cross Validation, Grid Search, Ablation Study và tập Test độc lập, trước khi đóng gói hoàn chỉnh vào giao diện Dashboard điều khiển thời gian thực trên nền tảng Django phục vụ giám

Memory Problems," *arXiv preprint arXiv:1512.08756*, 2016. [Online]. Available: <https://arxiv.org/abs/1512.08756>.

⁹ Mã nguồn toàn bộ dự án tại Github: <https://github.com/ChucNamNo/Fall-Detection>

sát thực địa.


1.1.4. Phát biểu bài toán

Trọng tâm nghiên cứu của đề tài là xây dựng hệ thống tự động phân loại hai trạng thái hành vi bao gồm sự Fall (sự cố té ngã) và ADL (hoạt động sinh hoạt hằng ngày bình thường) từ luồng video thời gian thực, hướng tới mục tiêu hỗ trợ giám sát an toàn cho mọi người, đặc biệt là cho người cao tuổi.

Dữ liệu đầu vào (Input) của hệ thống là các đoạn video ghi lại chuỗi hành vi mô phỏng được trích xuất từ bộ dữ liệu chuẩn IMVIA Le2i Fall Detection Dataset¹⁰. Dữ liệu này được thu thập tại bốn không gian thực tế khác nhau bao gồm phòng khách, phòng cà phê, văn phòng và phòng học (Home, Coffee room, Office, Lecture room) với độ phân giải 320 x 240 pixels, tốc độ 25 khung hình/giây (FPS) và đi kèm tệp nhãn chi tiết cho từng khung hình.

Quy trình xử lý dữ liệu được thiết kế theo luồng tiếp nối khép kín qua năm giai đoạn kỹ thuật chuẩn hóa. Đầu tiên, video đầu vào được giải mã thành các khung hình liên tiếp theo đúng thứ tự thời gian. Tiếp đó, mô hình học sâu YOLOv8n-Pose được áp dụng để trích xuất tọa độ không gian 2D của 17 điểm khớp cơ thể chuẩn COCO. Để dữ liệu đạt tính bất biến với vị trí cũng như khoảng cách từ đối tượng tới camera, tọa độ khung xương được chuẩn hóa không gian bằng cách dịch chuyển gốc tọa độ về tâm hông và chia tỷ lệ cho chiều cao cơ thể. Nhằm mô tả toàn diện sự biến thiên tư thế và năng lượng chuyển động, hệ thống biến đổi ma trận khung xương tĩnh thành bộ vector 102 chiều đặc trưng động học cho mỗi khung hình, bao gồm 34 đặc trưng vị trí, 34 đặc trưng vận tốc và 34 đặc trưng gia tốc. Cấu trúc phân tầng của vector đặc trưng này được mô hình hóa trực quan tại Hình 1. 2.

¹⁰ IMVIA Laboratory - University of Burgundy, "Le2i Fall Detection Dataset," [Online]. Available: <https://www.kaggle.com/datasets/tuyenldvn/falldataset-imvia/data>.




Hình 1. 2. Mô hình hóa cấu trúc Tensor 102 chiều đặc trưng động học cho mỗi khung hình.

Cuối cùng, kỹ thuật cửa sổ trượt kích thước 16 khung hình (tương đương khoảng 0.53 giây) với bước trượt stride = 4 (độ chồng lấp 75%) được áp dụng để đóng gói dữ liệu thành các tensor chuỗi thời gian kích thước 16 x 102, giúp bắt trọn khoảnh khắc chuyển tiếp hành vi đột ngột.

Về mô hình nhân diện, chuỗi đặc trưng động học sau xử lý được đưa vào mạng nơ-ron hồi quy hai chiều BiGRU tích hợp cơ chế chú ý Feed-Forward Soft Attention. Mô hình thực hiện phân tích các phụ thuộc thời gian hai chiều và tự động tính toán trọng số tập trung vào các khoảng thời gian mang biến thiên chuyển động quyết định.

Đầu ra (Output) của hệ thống là quyết định phân loại nhị phân theo thời gian thực tương ứng với nhãn 1 (Fall – phát hiện té ngã) hoặc nhãn 0 (ADL – sinh hoạt bình thường). Kết quả nhận diện này được truyền tải trực tiếp lên giao diện Dashboard để phục vụ quá trình theo dõi, cảnh báo và giám sát liên tục. Toàn bộ luồng xử lý khép kín từ video đầu vào đến quyết định phân loại đầu ra được tổng quát hóa trong Hình 1. 3.



Hình 1. 3. Sơ đồ luồng xử lý dữ liệu tổng thể từ video đầu vào đến kết quả dự đoán của hệ thống.

Qua sơ đồ luồng tổng thể, có thể thấy hệ thống thực hiện chuyển đổi biểu diễn dữ liệu từ dạng video thô sang chuỗi ma trận khung xương (Skeleton). Cách tiếp cận này giúp tối ưu hóa đáng kể dung lượng lưu trữ, giảm băng thông truyền tải và bảo vệ tuyệt đối quyền riêng tư cho người dùng. Đồng thời, việc kết hợp giữa vector 102 chiều đặc trưng động học và mạng BiGRU-Attention cho phép hệ thống phân tích chính xác năng lượng chuyển động, đưa ra cảnh báo Fall hoặc xác nhận trạng thái an toàn ADL theo thời gian thực.

1.2. Động lực và mục tiêu nghiên cứu

1.2.1. Động lực

Xuất phát từ thực trạng nguy cơ té ngã ở người cao tuổi cùng các hạn chế cố hữu của phương pháp truyền thống (thiết bị đeo gây bất tiện, camera RGB xâm phạm quyền riêng tư), đề tài được thực hiện nhằm xây dựng một giải pháp giám sát tự động, liên tục.

Động lực cốt lõi của đề tài là khai thác tối đa ưu thế của dữ liệu khung xương (Skeleton) kết hợp cùng các đặc trưng động học và mô hình học chuỗi thời gian chuyên sâu. Hướng tiếp cận này nhằm giải quyết các vấn đề đề bài toán có thể nhận diện các pha biến thiên chuyển động đột ngột, từ đó nâng cao độ nhạy phát hiện sự cố, giảm thiểu báo động giả và đạt được khả năng triển khai trong thời gian thực trên hệ thống giám sát thực tế.

1.2.2. Mục tiêu dự án

Mục tiêu tổng quát của đề tài nghiên cứu, thiết kế và thực nghiệm thành công một hệ thống tự động nhận diện hành vi té ngã theo thời gian thực từ luồng video, thông qua việc kết hợp kỹ thuật ước lượng tư thế, dữ liệu khung xương chuẩn hóa và mô hình học sâu chuyên sâu. Hệ thống hướng tới việc nâng cao độ tin cậy trong việc phát hiện sự cố, giảm thiểu tối đa tỷ lệ báo động giả và đảm bảo quyền riêng tư cho người sử dụng.

Để thực hiện hóa mục tiêu tổng quát, đề tài triển khai ba nhóm mục tiêu cụ thể:

Thứ nhất là mục tiêu kỹ thuật và xử lý dữ liệu. Đề tài xây dựng luồng xử lý tự động khép kín từ video thô, tự động tách khung hình và trích xuất tọa độ 17 điểm khớp bằng mô hình YOLOv8n-Pose. Dữ liệu tọa độ được chuẩn hóa không gian về

tâm hông và chia tỷ lệ chiều cao cơ thể nhằm đạt tính bất biến với khoảng cách và vị trí camera. Đồng thời, hệ thống hoàn thiện kỹ thuật trích xuất đặc trưng động học 102 chiều (kết hợp vị trí, vận tốc và gia tốc) và đóng gói chuỗi thời gian bằng cửa sổ trượt kích thước 16 khung hình với độ chồng lấp 75%;

Thứ hai là mục tiêu xây dựng và tối ưu hóa mô hình. Nhóm nghiên cứu thiết kế kiến trúc BiGRU kết hợp cơ chế Feed-Forward Soft Attention để học sâu ngữ cảnh chuỗi thời gian hai chiều. Hệ thống tích hợp hàm mất mát Focal Loss ($\alpha = 0.50, \gamma = 2.0$) cũng kỹ thuật tăng cường Skeleton Jittering nhằm giải quyết triệt để bài toán mất cân bằng nhãn 3:1. Hiệu năng của mô hình được đánh giá và đối sánh định lượng thông qua các chỉ số học thuật tiêu chuẩn, trong đó đặc biệt ưu tiên tối đa hóa chỉ số Recall đối với lớp té ngã;

Thứ ba là mục tiêu ứng dụng và triển khai thực nghiệm. Đề tài hoàn thiện giao diện Dashboard trực quan cho phép truyền nhận luồng dữ liệu, hiển thị kết quả phân loại và phát cảnh báo thời gian thực. Trên cơ sở đó, hệ thống được đánh giá toàn diện về khả năng thích ứng và triển khai thực tế trong môi trường y tế thông minh, viện dưỡng lão và hộ gia đình.

1.3. Phạm vi đề tài

Phạm vi nghiên cứu và triển khai của đề tài được xác định và giới hạn trên các phương diện chính:

Về đối tượng và dữ liệu nghiên cứu, đề tài tập trung giải quyết bài toán phân loại nhị phân giữa hai trạng thái hành vi Fall và ADL dựa trên tập dữ liệu chuẩn IMVIA Le2i Fall Detection Dataset thu thập tại bốn không gian thực tế gồm phòng khách, phòng làm việc, phòng pha cà phê và phòng học.

Về phương pháp xử lý dữ liệu và mô hình hóa, nghiên cứu ứng dụng mô hình YOLOv8n-Pose để trích xuất 17 điểm khung xương chuẩn COCO nhằm bảo vệ quyền riêng tư người dùng. Dữ liệu sau đó được chuẩn hóa không gian và chuyển đổi thành vector 102 chiều đặc trưng động học dạng chuỗi thời gian qua kỹ thuật cửa sổ trượt. Mô hình nhận diện trung tâm được xây dựng trên nền tảng BiGRU kết hợp Feed-Forward Soft Attention, cấu hình hàm tổn thất Focal Loss và kỹ thuật Skeleton Jittering. Quá trình kiểm thử được thực hiện nghiêm ngặt thông qua phương pháp 5-Fold Cross Validation cùng với các chỉ số Accuracy, Precision, Recall và F1-score.

Về sản phẩm và giới hạn kỹ thuật, đề tài tập trung hoàn thiện giao diện Dashboard thử nghiệm cho phép tiếp nhận video và trực quan hóa kết quả phân loại thời gian thực. Đề tài giới hạn phạm vi trong việc phân loại hai trạng thái hành vi đơn lẻ; đồng thời chưa xử lý chuyên sâu các trường hợp đối tượng bị che khuất nghiêm trọng trong thời gian dài.

1.4. Nhân sự và Phân công nhiệm vụ

Đề tài được phối hợp triển khai bởi bốn thành viên với cơ chế phân công nhiệm vụ rõ ràng theo từng mảng chuyên môn, vừa đảm bảo tính chuyên sâu của từng hợp phần kỹ thuật, vừa duy trì tính liên kết chặt chẽ trong toàn bộ quy trình phát triển hệ thống.

Trách nhiệm và phạm vi công việc cụ thể của từng thành viên được xác định như sau:

Thành viên 1: Khảo sát và Đề xuất giải pháp kỹ thuật

- Chủ trì khảo sát các tài liệu nghiên cứu liên quan đến bài toán nhận diện té ngã bằng Trí tuệ nhân tạo và Thị giác máy tính;
- Đề xuất ý tưởng, định hướng giải pháp kỹ thuật tổng thể cho hệ thống;
- Phụ trách hỗ trợ và hoàn thiện cấu trúc nội dung slide báo cáo kỹ thuật của dự án.

Thành viên 2: Thu thập và Tiền xử lý dữ liệu

- Thu thập, cấu trúc và quản lý bộ dữ liệu IMVIA Le2i Fall Detection Dataset; xử lý tệp Annotation;
- Ứng dụng mô hình YOLOv8n-Pose để bóc tách và trích xuất tọa độ 2D và 17 điểm khớp khung xương (keypoints).
- Xây dựng dữ liệu khung xương thô, thực hiện các bước chuẩn hóa không gian và lọc nhiễu tọa độ đầu vào.
- Tổng hợp và hoàn thiện bài báo cáo dự án.

Thành viên 3: Trích xuất đặc trưng và Xây dựng mô hình:

- Thiết kế bộ vector 102 chiều đặc trưng động học (Kinematic Features) kết hợp giữa Vị trí, Vận tốc và Gia tốc;

- Áp dụng kỹ thuật cửa sổ trượt (Sliding Window) để cấu trúc hóa dữ liệu thành các tensor chuỗi thời gian;
- Thiết lập và tối ưu hóa kiến trúc mạng nơ-ron hồi quy hai chiều BiGRU kết hợp cơ chế chú ý Feed-Forward Soft Attention;
- Cấu hình hàm mất mát Focal Loss ($\alpha = 0.50, \gamma = 2.0$), tích hợp kỹ thuật Skeleton Jittering và thực hiện tinh chỉnh siêu tham số bằng Grid Search;
- Thiết lập kịch bản thực nghiệm, thực hiện kiểm thử 5-Fold Cross Validation, nghiên cứu bóc tách (Ablation Study) và phân tích các chỉ số đánh giá định lượng (Accuracy, Precision, Recall, F1-score, Confusion Matrix).

Thành viên 4: Giao diện và Tích hợp hệ thống:

- Thiết kế và xây dựng giao diện Dashboard điều khiển (UI/UX) trên nền tảng Django framework;
- Tích hợp toàn bộ luồng suy luận của mô hình vào hệ thống, kiểm thử độ trễ và khả năng phân loại theo thời gian thực trên luồng video/webcam;
- Phối hợp kiểm thử thực tế, đóng góp phân tích kết quả vận hành hệ thống và thiết kế slide báo cáo.

Bảng 1. 1. Phân công công việc của các thành viên.

STT	Thành viên	Nhiệm vụ chính
1	Trần Đức Mạnh	Khảo sát tài liệu, đề xuất định hướng giải pháp kỹ thuật, và hỗ trợ hoàn thiện slide báo cáo.
2	Trần Thị Hảo	Thu thập và xử lý bộ dữ liệu IMVIA Le2i, trích xuất khung xương bằng YOLOv8n-Pose, chuẩn hóa không gian và tổng hợp báo cáo dự án.
3	Phạm Long Chúc	Kỹ thuật đặc trưng động học 102 chiều, xây dựng và huấn luyện mô hình BiGRU-Attention, tối ưu hóa siêu tham số, thực nghiệm 5-Fold CV và theo dõi tiến độ tổng thể và hỗ trợ viết báo cáo.

4	Nguyễn Xuân Linh	Phát triển giao diện Dashboard (Django UI/UX), tích hợp hệ thống xử lý luồng thời gian thực và thiết kế slide thuyết trình.
---	------------------	---

Việc phân công theo bốn nhóm nhiệm vụ giúp các thành viên có trách nhiệm rõ ràng trong từng giai đoạn, đồng thời vẫn đảm bảo sự phối hợp giữa khâu Dữ liệu – Mô hình – thực nghiệm – Giao diện ứng dụng.

1.5. Kế hoạch và Các mốc tiến độ

Nhằm đảm bảo tiến độ triển khai và chất lượng học thuật của dự án, lộ trình nghiên cứu được chia thành năm giai đoạn tiếp nối. Mỗi giai đoạn đều xác định rõ ràng mục tiêu kỹ thuật và sản phẩm đầu ra tương ứng:

Giai đoạn 1 – Khảo sát và Xác định bài toán:

- Nghiên cứu cơ sở lý thuyết về bài toán phát hiện té ngã, ứng dụng thị giác máy tính và trích xuất tư thế (Pose Estimation);
- Khảo sát, phân tích các đặc trưng của bộ dữ liệu IMVIA Le2i Fall Detection Dataset;
- Tổng nhất phương án kỹ thuật và khung công nghệ: YOLOv8n-Pose + Kinematic Features + BiGRU-Attention.

Giai đoạn 2 – Thu thập và Tiền xử lý dữ liệu:

- Giải mã video, xử lý tệp Annotation và trích xuất tọa độ 17 điểm khớp khung xương bằng YOLOv8n-Pose;
- Thực hiện chuẩn hóa không gian (dời gốc tọa độ về tâm hông và chia tỷ lệ cho chiều cao cơ thể);
- Biến đổi vector 102 chiều đặc trưng động học và áp dụng kỹ thuật cửa sổ trượt (window size = 16, stride = 4) để tạo lập tập dữ liệu chuỗi thời gian.

Giai đoạn 3 – Xây dựng và Huấn luyện mô hình:

- Xây dựng và thử nghiệm các kiến trúc nền tảng bao gồm CNN-1D, GRU, LSTM và BiGRU;
- Hoàn thiện kiến trúc đề xuất BiGRU kết hợp cơ chế chú ý Feed-Forward Soft Attention;

- Tích hợp hàm mất mát Focal Loss và kỹ thuật tăng cường dữ liệu Skeleton Jittering $N(0,0.02)$ nhằm khắc phục hiện tượng mất cân bằng lớp.

Giai đoạn 4 – Đánh giá thực nghiệm và Lựa chọn mô hình:

- Tiến hành kiểm thử chéo 5-Fold Cross Validation trên toàn bộ dữ liệu;
- Đo đạc và phân tích chi tiết các chỉ số hiệu năng: Accuracy, Precision, Recall, F1-score và ma trận nhầm lẫn (Confusion Matrix);
- Thực hiện nghiên cứu bóc tách thành phần (Ablation Study) và khảo sát ma trận siêu tham số Focal Loss để khẳng định tính ưu việt của mô hình đề xuất.

Giai đoạn 5 – Xây dựng giao diện và hoàn thiện hệ thống

- Xây dựng ứng dụng Dashboard trực quan trên nền tảng Django, hỗ trợ nạp video và hiển thị kết quả phân loại theo thời gian thực;
- Kiểm thử khả năng vận hành của hệ thống, đóng gói sản phẩm và hoàn thiện báo cáo tổng kết.

Bảng 1. 2. Kế hoạch thực hiện và các mốc chính.

Giai đoạn	Nội dung công việc	Kết quả
1	Khảo sát tài liệu, xác định bài toán và lựa chọn bộ dữ liệu.	Báo cáo tổng quan lý thuyết và đề xuất phương án kỹ thuật.
2	Trích xuất điểm khớp bằng YOLOv8n-Pose, chuẩn hóa không gian và kỹ thuật đặc trưng.	Tập dữ liệu tensor chuỗi đặc trưng động học 102 chiều chuẩn hóa.
3	Thiết kế kiến trúc, cấu hình hàm mất mát Focal Loss và huấn luyện các mô hình học sâu.	Mô hình BiGRU-Attention tối ưu trọng số.
4	Kiểm thử 5-Fold Cross Validation, quét lưới siêu tham số và thực hiện Ablation Study.	Báo cáo thực nghiệm đối sánh định lượng và ma trận nhầm lẫn.

5	Phát triển giao diện Web Dashboard, tích hợp hệ thống thời gian thực và tổng hợp báo cáo.	Hệ thống phần mềm hoàn chỉnh và báo cáo dự án Capstone.
----------	---	---

2. TRIỂN KHAI ĐỀ TÀI

2.1. Thu thập dữ liệu

2.1.1. Giới thiệu bộ dữ liệu

Đề tài sử dụng IMVIA Le2i Fall Detection Dataset làm nguồn dữ liệu chính để xây dựng hệ thống phát hiện té ngã. Đây là bộ dữ liệu công khai gồm các video ghi lại nhiều hoạt động của con người trong những điều kiện và bối cảnh khác nhau.

Bộ dữ liệu IMVIA Le2i cung cấp hệ thống các video ghi lại đa dạng hoạt động của con người được thu thập tại bốn không gian thực tế khác nhau bao gồm phòng khách, phòng pha cà phê, văn phòng và phòng học (Home, Coffee room, Office, Lecture room). Các chuỗi hành vi trong bộ dữ liệu được phân chia thành hai nhóm nhãn cốt lõi:

- ADL (Activities of Daily Living): Bao gồm các chuỗi hành động sinh hoạt hằng ngày bình thường như đi lại, ngồi xuống, đứng lên hoặc cúi người;

- Fall: Bao gồm các tình huống mô phỏng hành vi té ngã nguy hiểm xảy ra trong nhiều điều kiện bối cảnh khác nhau.

Bên cạnh dữ liệu video, bộ dữ liệu còn cung cấp thông tin Annotation. Annotation được sử dụng để xác định các đoạn video hoặc khoảng thời gian liên quan đến hành vi té ngã, từ đó hỗ trợ quá trình xác định nhãn cho dữ liệu.

Trong quá trình chuẩn bị dữ liệu, nhóm sử dụng thông tin Annotation kết hợp với nội dung video để xác định trạng thái tương ứng của các mẫu dữ liệu. Các dữ liệu sau khi được xác định nhãn được chuẩn bị cho bước tiền xử lý và chuyển đổi sang dạng Skeleton.

Tóm lại, quy trình khai thác nguồn dữ liệu đầu vào của đề tài được tổng quát hóa theo sơ đồ chuyển đổi sau:

IMVIA Le2i Fall Detection Dataset → Video + Annotation → Dữ liệu được gán nhãn.

2.1.2 Đặc điểm và thống kê dữ liệu

Sau quá trình trích xuất và xử lý sơ bộ, bộ dữ liệu thu được tổng cộng 10.091 mẫu chuỗi thời gian, được phân chia thành hai lớp hành vi chính bao gồm ADL (hoạt động sinh hoạt hằng ngày) và Fall (té ngã).

Bảng 2. 1. Thống kê bộ dữ liệu.

Nhãn	Ý nghĩa	Số mẫu	Tỷ lệ
0	ADL (Bình thường)	7,628	75.6%
1	Fall (Té ngã)	2,463	24.4%
Tổng		10,091	100%

Từ bảng thống kê trên có thể thấy, bộ dữ liệu xuất hiện sự chênh lệch đáng kể về mặt số lượng giữa hai lớp nhãn, trong đó lớp ADL chiếm ưu thế với 75.6% (7,628 mẫu) còn lớp Fall chỉ chiếm 24.4% (2,463 mẫu). Đặc điểm này thể hiện bài toán tồn tại tình trạng mất cân bằng lớp (Class Imbalance) nghiêm trọng với tỷ lệ chênh lệch xấp xỉ 3:1.

Bên cạnh sự mất cân bằng về số lượng, dữ liệu thực nghiệm còn sở hữu một số đặc điểm kỹ thuật quan trọng cần được cân nhắc kỹ lưỡng trong quá trình thiết kế hệ thống:

- Sự đa dạng và thách thức trong hành vi: Các hoạt động ADL chứa đựng nhiều dạng tư thế phức tạp, trong đó một số hành vi bình thường (như ngồi xuống nhanh, cúi gập người) có đặc trưng chuyển động gần tương đồng với sự cố té ngã;

- Tính chất chuỗi thời gian: Chuyển động của đối tượng biến thiên liên tục theo thời gian, đòi hỏi mô hình phải ghi nhận được tính phụ thuộc giữa các khung hình nối tiếp;

- Sự biến đổi không gian và góc nhìn: Vị trí của người trong khung hình, góc quay camera và điều kiện ánh sáng môi trường giữa các video có sự khác biệt lớn, dễ làm ảnh hưởng đến độ chính xác của thông tin tư thế thô.

Những đặc điểm trên được xem xét khi lựa chọn phương pháp tiền xử lý và mô hình học sâu ở các bước tiếp theo.

2.1.3. Chiến lược phân chia dữ liệu

Sau khi hoàn tất khâu chuẩn bị và gán nhãn, toàn bộ 10,091 mẫu dữ liệu được nhóm nghiên cứu tiến hành phân chia thành ba tập dữ liệu độc lập bao gồm Train Set (70%), Validation Set (15%) và Test Set (15%).

Nhằm đảm bảo tỷ lệ phân bố giữa hai lớp ADL và Fall được giữ nguyên đồng nhất trên cả ba tập, kỹ thuật Stratified Split (Phân tầng) đã được áp dụng, giúp duy trì ổn định tỷ lệ chênh lệch lớp 3: 1 (24.4% mẫu Fall).

Bảng 2. 2. Phân chia chi tiết bộ dữ liệu Train – Validation – Test.

Tập dữ liệu	Tỷ lệ phân chia	Số mẫu ADL (Nhãn 0)	Số mẫu Fall (Nhãn 1)	Tổng số mẫu
Train Set	70.0%	5,340	1,724	7,064
Validation Set	15.0%	1,144	369	1,513
Test Set	15.0%	1,144	370	1,514
Tổng cộng	100%	7,628	2,463	10,091

2.2. Tiền xử lý dữ liệu

Sau khi dữ liệu được chuẩn bị và phân chia, nhóm tiến hành tiền xử lý nhằm chuyển dữ liệu video ban đầu thành dạng Skeleton theo chuỗi thời gian phù hợp với mô hình học sâu.

Mục tiêu của bước này là tạo ra biểu diễn dữ liệu chứa thông tin về tư thế và chuyển động của con người, đồng thời giảm sự phụ thuộc vào thông tin hình ảnh không cần thiết như màu sắc hoặc phong nền và điều kiện ánh sáng, giúp tối ưu hóa dung lượng tính toán và bảo vệ quyền riêng tư.

Luồng tiền xử lý được thiết kế nối tiếp qua các bước kỹ thuật chính sau:

Frame → Skeleton → Spatial Normalization → Motion Features → Sliding Window → Augmentation

2.2.1. Đọc video và Bóc tách nhãn Annotation

Giai đoạn đầu tiên trong luồng tiền xử lý là đọc luồng video thô và đồng bộ hóa với thông tin nhãn (ground truth) để chuẩn bị dữ liệu đầu vào cho mô hình trích xuất tư thế. Nhóm nghiên cứu sử dụng thư viện OpenCV để giải mã và đọc từng khung hình (frame) từ các tệp video có độ phân giải 320 x 240 pixels với tốc độ 25 FPS. Quá trình tách khung hình bắt buộc phải duy trì chính xác thứ tự thời gian tuyến tính để bảo toàn trọn vẹn thông tin biến thiên chuyển động của đối tượng.

Mỗi video trong bộ dữ liệu IMVIA Le2i đi kèm với một tệp cấu hình dạng .txt nằm trong thư mục Annotation_files ghi nhận chi tiết trạng thái hành vi qua từng

khung hình. Để xây dựng tập nhãn té ngã một cách chính xác, hệ thống triển khai bộ bóc tách nhãn nâng cao hỗ trợ xử lý song song hai định dạng cấu trúc:

- Dạng dải khoảng khung hình (Range format): Đọc các giá trị ghi nhận thời điểm bắt đầu (start_fall) và thời điểm kết thúc (end_fall) của sự cố té ngã tại các dòng đầu tiên của tập nhãn, từ đó gán nhãn té ngã cho toàn bộ dải khung hình nằm trong khoảng này;

- Dạng mã trạng thái (Status code format): Quét từng dòng dữ liệu theo cấu trúc cặp (frame_idx, status_code). Hệ thống tự động lọc các khung hình mang mã trạng thái thuộc tập {2; 4; 7; 8} (đại diện cho các giai đoạn mất thăng bằng, va chạm và nằm trên sàn) để nạp trực tiếp vào tập nhãn té ngã.

Việc bóc tách nhãn chuẩn xác kết hợp với việc duy trì chuỗi khung hình nối tiếp cho phép hệ thống biểu diễn video dưới dạng tập hợp các khung hình đã gán nhãn chi tiết, tạo tiền đề cho bước trích xuất điểm khớp ở giai đoạn tiếp theo.

2.2.2. Trích xuất điểm khớp cơ thể (Keypoint Extraction)

Sau khi tách chuỗi khung hình, hệ thống đưa trực tiếp từng hình ảnh màu vào mô hình thị giác học sâu YOLOv8n-Pose để tự động phát hiện đối tượng người và trích xuất tọa độ không gian 2D của 17 điểm khớp chuẩn COCO.

Quy trình trích xuất được thực hiện qua các bước tuần tự sau:

- Phát hiện đối tượng: Mô hình phát hiện người trong khung hình và xác định vùng chứa cơ thể;

- Định vị khớp cơ thể: Xác định vị trí tọa độ (x; y) của 17 điểm keypoints trên cơ thể;

- Cấu trúc dữ liệu Skeleton: Trích xuất mảng tọa độ và sắp xếp nối tiếp theo trục thời gian.

Việc chuyển đổi từ hình ảnh RGB thô sang biểu diễn ma trận Skeleton giúp loại bỏ hoàn toàn các thông tin dư thừa về màu sắc, phong nền và ánh sáng, giúp mô hình tập trung tuyệt đối vào tư thế động học, đồng thời bảo vệ quyền riêng tư cá nhân và tiết kiệm băng thông khi triển khai thực tế.

2.2.3. Chuẩn hóa Không gian Khung xương (Spatial Normalization)

Để giúp vector đặc trưng đạt tính bất biến với vị trí, khoảng cách và góc nhìn của camera đối với đối tượng, ma trận tọa độ KP của từng frame được chuẩn hóa theo công thức:

$$KP_{\text{shifted}} = KP - C_{\text{hip}}$$

$$KP_{\text{normalized}} = \frac{KP_{\text{shifted}}}{H_{\text{body}}}$$

Trong đó:

- Tâm hông (C_{hip}): Được xác định bằng trung điểm tọa độ của 2 khớp hông trái và phải (Keypoint 11 và 12):


$$C_{\text{hip}} = \frac{KP[11] + KP[12]}{2}$$

- Chiều cao cơ thể ước tính (H_{body}): Tính bằng khoảng cách theo trục thẳng đứng (Y) từ đỉnh đầu/mũi (Keypoint 0) đến vị trí thấp nhất của hai cổ chân (Keypoint 15 và 16):

$$H_{\text{body}} = \max(|Y_{\text{foot}} - Y_{\text{head}}|, 1.0)$$

(Lưu ý: Mẫu số H_{body} được giới hạn giá trị tối thiểu là 1.0 để phòng tránh lỗi chia cho 0).

Sau bước chuẩn hóa này, gốc tọa độ của cơ thể luôn được dời về tâm hông và kích thước cơ thể được đưa về tỷ lệ chuẩn, giúp mô hình phân tích hành vi độc lập với kích thước đối tượng hay khoảng cách xa gần so với camera.




Hình 2. 1. Sơ đồ mô tả quy trình chuẩn hóa không gian dời gốc tọa độ về tâm hông.

2.2.4. Trích xuất đặc trưng động học (Kinematic Feature Engineering)

Tọa độ khung xương tĩnh chỉ phản ánh tư thế tại một thời điểm đơn lẻ. Trong khi đó, hành vi té ngã mang đặc trưng là sự biến đổi năng lượng và tốc độ chuyển động đột ngột theo thời gian. Do đó, hệ thống tiến hành vi phân theo trục thời gian để tính toán bổ sung hai đại lượng động học bao gồm Vận tốc (đạo hàm bậc 1) và Gia tốc (đạo hàm bậc 2).

Bộ vector đặc trưng động học của mỗi khung hình bao gồm ba thành phần:

- Position (Vị trí): Tọa độ không gian chuẩn hóa (x; y) của 17 keypoints ($17 \times 2 = 34$ đặc trưng);
- Velocity (Vận tốc): Sai phân bậc 1 của vị trí giữa hai khung hình liên tiếp ($17 \times 2 = 34$ đặc trưng);
- Acceleration (Gia tốc): Sai phân bậc 2 biểu diễn sự biến thiên của vận tốc theo thời gian ($17 \times 2 = 34$ đặc trưng).



Hình 2. 2. Mô hình hóa cấu trúc Tensor 102 chiều đặc trưng động học cho mỗi khung hình.

2.2.5. Tạo chuỗi dữ liệu bằng Sliding Window

Để mô hình học sâu có thể phân tích được ngữ cảnh thời gian, dữ liệu sau khi trích xuất 102 chiều đặc trưng tiếp tục được đóng gói thành các chuỗi thời gian (Time-series sequences) bằng kỹ thuật cửa sổ trượt (Sliding Window).


Các thông số cấu hình cửa sổ trượt được thiết lập như sau:

- Kích thước cửa sổ (Window Size - W): 16 khung hình liên tiếp (tương đương ~ 0.53 giây quan sát động học ở tốc độ 25 FPS);
- Bước trượt (Stride - S): 4 khung hình. Tỷ lệ chồng lấp 75% giữa các cửa sổ giúp tăng cường số lượng mẫu huấn luyện và bắt trọn các khoảnh khắc chuyển tiếp

hành vi đột ngột;

- Kích thước mẫu đầu vào (Input Tensor Shape): Tensor hai chiều kích thước 16×102 (gồm 16 bước thời gian, mỗi bước chứa 102 chiều đặc trưng);
- Quy tắc gán nhãn chuỗi: Nhãn của cửa sổ được gán giá trị 1 (Fall) và 0 (ADL).

Dạng dữ liệu tensor (16, 102) này cung cấp đầy đủ thông tin về sự thay đổi trạng thái chuyển động theo thời gian, hoàn toàn thích hợp làm đầu vào cho các kiến trúc mạng hồi quy như BiGRU, LSTM hay GRU.



Hình 2. 3. Sơ đồ nguyên lý phân cụm chuỗi thời gian bằng kỹ thuật cửa sổ trượt (Sliding Window).

2.2.6. Tăng cường dữ liệu

Để giải quyết tình trạng mất cân bằng nhãn và nâng cao khả năng tổng quát hóa của mô hình, nhóm nghiên cứu áp dụng kỹ thuật tăng cường dữ liệu khung xương Skeleton Jittering trực tiếp trên tập huấn luyện (Train Set).


Quy trình tăng cường dữ liệu được triển khai như sau:

- Phương pháp: Bổ sung nhiễu trắng Gaussian $N(0, 0.02)$ vào tọa độ các điểm khớp với xác suất 50% đối với các mẫu thuộc nhãn té ngã (Fall);
- Mục đích: Tạo ra các biến thể tư thế ngã đa dạng hơn, ép mô hình không bị quá khớp (Overfitting) vào các tọa độ cứng nhắc và tăng độ bền vững trước nhiễu trích xuất keypoint từ camera;
- Phạm vi áp dụng: Kỹ thuật này chỉ áp dụng duy nhất trên Train Set. Tập Validation Set và Test Set được giữ nguyên bản tuyệt đối để đảm bảo tính khách quan và chính xác của quá trình đánh giá kiểm thử.

2.2.7. Kết quả sau tiền xử lý

Sau khi hoàn tất toàn bộ quy trình tiền xử lý, dữ liệu video thô ban đầu được chuyển đổi hoàn toàn thành các mảng tensor khung xương dạng chuỗi thời gian đã gán nhãn chuẩn xác.

Toàn bộ quá trình được khái quát:



Hình 2. 4. Sơ đồ luồng quy trình tiền xử lý dữ liệu từ video thô sang chuỗi tensor khung xương.

Kết quả đầu ra của quá trình tiền xử lý được lưu trữ dưới dạng hai tệp NumPy nén gồm sequences.npy (chứa các mẫu chuỗi kích thước 16 x 102) và labels.npy (chứa mảng nhãn tương ứng 0 hoặc 1). Đây là nguồn dữ liệu chuẩn hóa trực tiếp đưa vào bước huấn luyện, tối ưu hóa và so sánh hiệu năng các mô hình học sâu.

2.3. Phương pháp huấn luyện

Sau khi hoàn tất quy trình tiền xử lý dữ liệu và tạo lập các mảng tensor đặc trưng dạng chuỗi thời gian, nhóm nghiên cứu tiến hành xây dựng phương pháp huấn luyện chuyên sâu nhằm tìm ra kiến trúc mô hình tối ưu cho dữ liệu khung xương dạng chuỗi. Mục tiêu cốt lõi của quá trình huấn luyện là xây dựng một mô hình có khả năng phân biệt chính xác hai trạng thái hành vi: nhãn 1- Fall (sự cố té ngã) và nhãn 0 - ADL (hoạt động sinh hoạt hằng ngày).

2.3.1. Các mô hình được khảo sát

Để tìm ra kiến trúc tối ưu nhất cho bài toán phát hiện té ngã từ chuỗi dữ liệu khung xương, nhóm nghiên cứu đã tiến hành khảo sát và đánh giá định lượng 4 kiến trúc học sâu chuyên biệt thông qua phương pháp kiểm thử chéo 5-Fold Cross Validation. Các mô hình được huấn luyện trong 40 epochs và đo đạc các chỉ số trung bình trên tập kiểm thử (*Test Set*) của từng Fold.

Đặc điểm và kết quả thực nghiệm của từng kiến trúc mô hình khảo sát bao gồm:

- BiGRU-Attention (Mô hình đề xuất — Tối ưu được lựa chọn): Kết hợp mạng hồi quy hai chiều BiGRU với cơ chế chú ý Feed-Forward Soft Attention, đạt hiệu năng tổng hợp cao nhất với chỉ số F1-Score trung bình đạt 87.13%, dung lượng 139,266 tham số và chi phí tính toán 4.51 MFLOPs cho một chuỗi 16 khung hình;

- GRU (Mô hình tham khảo): Mạng hồi quy tối giản hệ thống công, đạt chỉ số F1-Score trung bình 84.64%, sở hữu 57,281 tham số và chi phí tính toán 1.86 MFLOPs;

- LSTM (Mô hình tham khảo): Mạng hồi quy bộ nhớ dài-ngắn hạn, đạt chỉ số F1-Score trung bình 83.02%, chứa 76,353 tham số và chi phí tính toán 2.47 MFLOPs;

- CNN-1D (Mô hình tham khảo): Mạng tích chập 1 chiều siêu nhẹ với 19,713 tham số và chi phí 0.63 MFLOPs, tuy nhiên hiệu năng nhận diện khiêm tốn nhất với F1-Score trung bình chỉ đạt 72.19% do hạn chế trong việc học các phụ thuộc chuỗi thời gian dài.

Bảng tổng hợp so sánh chi tiết hiệu năng và độ phức tạp tính toán giữa các kiến trúc được thể hiện trong Bảng 2. 3 dưới đây:

Bảng 2. 3. So sánh hiệu năng 4 kiến trúc (5-Fold Cross Validation).

Mô hình (Model)	Mean F1-Score	Parameters	FLOPs (16 frames)	Trạng thái
BiGRU-Attention	87.13%	139,266	4.51 MFLOPs	Tối ưu (Selected)
GRU	84.64%	57,281	1.86 MFLOPs	Tham khảo
LSTM	83.02%	76,353	2.47 MFLOPs	Tham khảo
CNN-1D	72.19%	19,713	0.63 MFLOPs	Tham khảo

Kết quả trung bình sau 40 epochs huấn luyện, kiểm thử trên tập Test của từng Fold.

Từ kết quả thực nghiệm có thể thấy, kiến trúc BiGRU-Attention vượt trội toàn diện về chỉ số F1-Score, cao hơn + 2.49% so với GRU đơn thuần và +4.11% so với LSTM. Mặc dù tiêu tốn 4.5 MFLOPs tài nguyên tính toán (gấp 2.4 lần so với GRU), mức dung lượng này vẫn rất nhẹ và hoàn toàn đáp ứng tốt ngưỡng xử lý thời gian thực trên các thiết bị phần cứng biên (Edge AI).

2.3.2. BiGRU kết hợp cơ chế chú ý Feed-Forward Soft Attention

Mô hình trung tâm của đề tài được phát triển dựa trên sự phối hợp giữa mạng nơ-ron hồi quy hai chiều BiGRU và cơ chế chú ý Feed-Forward Soft Attention. Sự kết hợp này cho phép hệ thống vừa khai thác trọn vẹn ngữ cảnh chuyển động hai chiều (quá khứ và tương lai) trong chuỗi thời gian, vừa tự động đánh giá và tập trung trọng số vào các thời điểm then chốt diễn ra sự cố té ngã.

a. Khối Mạng BiGRU (Bidirectional GRU)

Mạng GRU truyền thống¹¹ giải quyết hiệu quả hiện tượng suy giảm đạo hàm (Vanishing Gradient) thông qua hệ thống cổng Cập nhật (Update Gate) và cổng Đặt lại (Reset Gate). Nhằm vượt qua hạn chế của mạng một chiều chỉ học được ngữ cảnh từ quá khứ, kiến trúc BiGRU¹² tiến hành xử lý chuỗi dữ liệu đầu vào theo hai hướng song song:

- Hướng thuận ($\vec{h}_t$): Quét dữ liệu theo chiều thời gian tuyến tính từ $t = 1 \rightarrow 16$ để học các phụ thuộc ngữ cảnh từ quá khứ đến hiện tại;

- Hướng ngược ($\overleftarrow{h}_t$): Quét dữ liệu ngược chiều thời gian từ $t = 16 \rightarrow 1$ để bổ sung ngữ cảnh tương lai cho các khung hình phía trước.

Trạng thái ẩn tổng hợp h_t tại mỗi bước thời gian t ($t \in [1,16]$) được tạo thành bằng cách nối trực tiếp vector trạng thái ẩn thuận và ngược:

$$h_t = [\vec{h}_t ; \overleftarrow{h}_t]$$

b. Cơ chế Chú ý Chi tiết (Feed-Forward Soft Attention Mechanism)

Trong các mô hình RNN truyền thống, trạng thái ẩn ở bước thời gian cuối cùng h_{16} thường được sử dụng làm đại diện cho toàn bộ chuỗi. Tuy nhiên, đối với bài toán nhận diện té ngã, sự cố ngã thường diễn ra đột ngột trong một khoảng thời gian ngắn ở giữa chuỗi khung hình, dẫn đến nguy cơ mất mát thông tin quan trọng

¹¹ [9] K. Cho *et al.*, "Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation," *arXiv preprint arXiv:1406.107*, pp. 1724-1734, 2014. [Online]. Available: <https://arxiv.org/abs/1406.1078>.

¹² [7] M. Schuster and K. K. Paliwal, "Bidirectional recurrent neural networks," *IEEE Transactions on Signal Processing*, vol. 45, pp. 2673-2681, 12/01 1997, doi: 10.1109/78.650093.

nếu chỉ xét h_{16} . Do đó, cơ chế Feed-Forward Soft Attention¹³ được tích hợp để tự động đánh giá và tính toán trọng số đóng góp α_t của từng bước thời gian t thông qua ba bước toán học:

- Điểm số chú ý (Attention Score):

$$e_t = W_a \cdot h_t + b_a$$

(Trong đó W_a và b_a lần lượt là ma trận trọng số và vector độ lệch của lớp Feed-Forward Attention);

- Trọng số chuẩn hóa (Attention Weights):


$$\alpha_t = \frac{\exp(e_t)}{\sum_{k=1}^{16} \exp(e_k)}$$

(Thừa số $\alpha_t \in [0,1]$ thỏa mãn $\sum_{t=1}^{16} \alpha_t = 1$, phản ánh mức độ tập trung trọng tâm vào khung hình thứ t);

- Vector ngữ cảnh (Context Vector):

$$c = \sum_{t=1}^{16} \alpha_t h_t$$

Vector ngữ cảnh c đóng vai trò cô đọng toàn bộ thông tin quan trọng từ các khung hình chứa biến thiên chuyển động lớn (giai đoạn mất thăng bằng hoặc va chạm). Cuối cùng, vector c được đưa qua lớp phân loại tuyến tính (Fully-Connected Layer) để dự đoán xác suất hai lớp nhãn Fall / ADL.



Hình 2. 5. Sơ đồ tính toán cơ chế chú ý Feed-Forward Soft Attention và tạo lập vector ngữ cảnh c .

¹³ [8] C. R. a. D. P. W. Ellis, "Feed-Forward Networks with Attention Can Solve Some Long-Term Memory Problems," *arXiv preprint arXiv:1512.08756*, 2016. [Online]. Available: <https://arxiv.org/abs/1512.08756>.

2.3.3. Phương pháp xử lý mất cân bằng dữ liệu

Do số lượng mẫu thuộc lớp sinh hoạt bình thường (ADL) chiếm đa số (75.6%) so với lớp té ngã (Fall) chỉ chiếm 24.4%, hiện tượng mất cân bằng lớp nghiêm trọng (tỷ lệ chênh lệch $\sim 3:1$) gây ra sự thiên lệch lực kéo gradient về phía lớp đa số. Nếu chỉ huấn luyện bằng các phương pháp thông thường, mô hình sẽ có xu hướng dự đoán thiên vị lớp ADL và bỏ sót các nguy cơ té ngã thực tế. Để khắc phục triệt để bài toán này, nhóm nghiên cứu kết hợp đồng thời hai kỹ thuật tác động từ hai cấp độ dữ liệu và hàm tổn thất:

- Hàm mất mát Focal Loss chuẩn hóa ($\alpha = 0.50, \gamma = 2.0$): Thay thế hàm tổn thất Binary Cross Entropy (BCE) truyền thống bằng Focal Loss nhằm làm suy giảm trọng số đóng góp của các mẫu dễ phân loại và tập trung gradient vào các mẫu khó ở vùng ranh giới hành vi. Trong đó, hệ số $\alpha = 0.50$ có vai trò cân bằng mức phạt tổn thất giữa hai lớp nhãn, trong khi tham số $\gamma = 2.0$ làm giảm mạnh trọng số đối với các mẫu có xác suất dự đoán đúng cao ($p_t > 0.9$), ép mô hình tập trung tối đa học các pha chuyển động phức tạp;

- Kỹ thuật tăng cường dữ liệu Skeleton Jittering: Trực tiếp trong quá trình huấn luyện (Training Loop), các chuỗi dữ liệu thuộc lớp té ngã (Fall) được bổ sung ngẫu nhiên nhiễu trắng Gaussian $N(0,0.02)$ với xác suất 50% đối với tọa độ các điểm khớp. Kỹ thuật này giúp tạo ra các biến thể tư thế ngã đa dạng hơn, mở rộng không gian mẫu cho lớp thiểu số và nâng cao độ bền vững trước nhiễu trích xuất keypoint từ camera.

Việc thiết lập cấu hình tham số $\alpha = 0.50$ và $\gamma = 2.0$ không dựa trên cảm tính mà là kết quả rút ra từ thực nghiệm quét ma trận siêu tham số 5×5 ($\gamma \times \alpha$) trên tập Validation. Chi tiết kết quả khảo sát định lượng và luận điểm lý giải cho bộ thông số tối ưu này sẽ được trình bày từ Bảng 3. 2 đến Bảng 3. 5.

3. KẾT QUẢ THỰC NGHIỆM

3.1. Tối ưu hóa siêu tham số mô hình (Grid Search)

Quá trình lựa chọn cấu hình siêu tham số giữ vai trò quyết định đến khả năng biểu diễn và độ ổn định của mạng nơ-ron học sâu. Đối với kiến trúc đề xuất BiGRU-Attention, nhóm nghiên cứu tiến hành tối ưu hóa cấu hình thông qua phương pháp tìm kiếm theo lưới (Grid Search) trên tập Validation. Không gian siêu tham số được khảo sát bao gồm ba thành phần cốt lõi: kích thước không gian ẩn $hidden_size \in [32; 64]$, số lớp hồi quy xếp chồng $num_layers \in [1; 2]$ và tốc độ học ban đầu $learning_rate \in [0.001; 0.005]$.

Thực nghiệm được thiết lập trên 8 tổ hợp cấu hình khác nhau, đo đạc trực tiếp thông qua hai chỉ số định lượng tiêu chuẩn là Val F1-Score (%) và Val Recall (%). Kết quả chi tiết của quá trình quét lưới được tổng hợp trong Bảng 3. 1:

Bảng 3. 1. Kết quả tối ưu hóa siêu tham số mô hình BiGRU-Attention bằng Grid Search.

STT	Hidden Size (H)	Num Layers (L)	Learning Rate (LR)	Val F1 (%)	Val Recall (%)
1	32	1	0.001	83.8%	86.7%
2	32	1	0.005	84.8%	86.4%
3	32	2	0.001	85.9%	86.4%
4	32	2	0.005	83.4%	84.0%
5	64	1	0.001	87.6%	85.1%
6	64	1	0.005	81.1%	79.3%
7	64	2	0.001	89.2%	91.0%
8	64	2	0.005	85.2%	82.9%

Val F1 (đơn-split, 20 epochs) được tính trên một tập validation cố định, không phải giá trị trung bình qua Cross-Validation; do đó có thể cao hơn Mean F1 ở mục 2.3.1.

Phân tích kết quả từ Bảng 3. 1 cho thấy sự biến động rõ rệt về hiệu năng nhận diện khi thay đổi không gian tham số:

- Ảnh hưởng của Tốc độ học (LR): Khi duy trì $LR = 0.001$, mô hình đạt độ hội tụ rất ổn định và liên tục ghi nhận kết quả F1-Score ở mức cao. Ngược lại, khi tăng tốc độ học lên $LR = 0.005$, hiệu năng ở hầu hết các cấu hình đều sụt giảm đáng

kể. Diễn hình ở cấu hình 6 ($H = 64$; $L = 1$; $LR = 0.005$), Val F1 giảm xuống mức thấp nhất là 81.1% và Val Recall chỉ đạt 79.3%. Điều này chứng tỏ tốc độ học lớn làm bước nhảy gradient bị dao động qua lại quanh cực trị địa phương, khiến mô hình khó hội tụ về điểm tối ưu.

- Tác động của Kích thước ẩn (H) và Số lớp (L): Việc mở rộng dung lượng mạng từ $H = 32$ lên $H = 64$ kết hợp với $L = 2$ lớp hồi quy xếp chồng giúp tăng cường đáng kể khả năng trích xuất các đặc trưng phi tuyến tính phức tạp trong chuỗi dữ liệu khung xương 102 chiều. Cấu hình với $H = 64$, $L = 2$ thể hiện khả năng học chuỗi vượt trội so với các mô hình đơn lớp hoặc dung lượng ẩn nhỏ.

Từ các phân tích trên, cấu hình tại STT 7 với kích thước ẩn $H = 64$, số lớp $L = 2$ và tốc độ học $LR = 0.001$ được xác định là cấu hình tối ưu nhất, đạt đỉnh hiệu năng với Val F1 bằng 89.2% và Val Recall đạt 91.0%.

3.2. Khảo sát ma trận siêu tham số Focal Loss ($\alpha \times \gamma$)

Nhằm giải quyết triệt để bài toán mất cân bằng dữ liệu 3: 1 giữa lớp sinh hoạt bình thường (ADL) và té ngã (Fall), nhóm nghiên cứu tiến hành bài thử nghiệm quét ma trận hai chiều để tìm kiếm cặp siêu tham số tối ưu cho hàm Focal Loss. Không gian khảo sát bao gồm hệ số cân bằng trọng số lớp $\alpha \in [0.10; 0.25; 0.50; 0.75; 0.90]$ và hệ số điều chỉnh trọng số mẫu khó $\gamma \in [0.1; 0.2; 0.5; 1.0; 2.0]$.

Thực nghiệm được đánh giá trên tập Validation trong suốt 20 epochs huấn luyện với cấu hình mạng cố định ($H = 64$; $L = 2$; $LR = 0.001$). Chỉ số Val F1-Score (%) được đo đặc đồng thời trên cả bốn kiến trúc mô hình (BiGRU-Attention, LSTM, GRU, CNN-1D) để làm cơ sở đối sánh toàn diện.

3.2.1. Ma trận kết quả trên các kiến trúc mô hình

Kết quả khảo sát ma trận siêu tham số Focal Loss ($\gamma \times \alpha$) chi tiết cho từng kiến trúc mô hình được trình bày từ Bảng 3. 2 đến Bảng 3. 5:

Bảng 3. 2. Ma trận khảo sát siêu tham số Focal Loss ($\gamma \times \alpha$) trên mô hình BiGRU-Attention (Val F1 %).

$\gamma \backslash \alpha$	$\alpha=0.10$	$\alpha=0.25$	$\alpha=0.50$	$\alpha=0.75$	$\alpha=0.90$
$\gamma = 0.1$	78.06%	82.14%	85.47%	85.56%	82.41%
$\gamma = 0.2$	77.81%	81.79%	85.39%	86.70%	83.17%
$\gamma = 0.5$	77.27%	82.26%	87.39%	87.18%	83.37%
$\gamma = 1.0$	76.05%	81.28%	86.49%	86.12%	82.77%
$\gamma = 2.0$	77.35%	81.80%	87.59%	85.24%	83.40%

Bảng 3. 3. Ma trận khảo sát siêu tham số Focal Loss ($\gamma \times \alpha$) trên mô hình LSTM (Val F1 %).

$\gamma \backslash \alpha$	$\alpha=0.10$	$\alpha=0.25$	$\alpha=0.50$	$\alpha=0.75$	$\alpha=0.90$
$\gamma = 0.1$	75.54%	81.39%	85.17%	82.52%	80.39%
$\gamma = 0.2$	75.71%	82.33%	84.59%	82.86%	78.87%
$\gamma = 0.5$	71.94%	81.28%	85.07%	84.31%	80.09%
$\gamma = 1.0$	74.07%	83.41%	84.62%	85.03%	81.32%
$\gamma = 2.0$	74.83%	83.43%	84.71%	82.38%	80.09%

Bảng 3. 4. Ma trận khảo sát siêu tham số Focal Loss ($\gamma \times \alpha$) trên mô hình GRU (Val F1 %).

$\gamma \backslash \alpha$	$\alpha=0.10$	$\alpha=0.25$	$\alpha=0.50$	$\alpha=0.75$	$\alpha=0.90$
$\gamma = 0.1$	73.56%	81.29%	83.48%	83.24%	78.52%
$\gamma = 0.2$	74.04%	79.33%	84.64%	83.45%	79.09%
$\gamma = 0.5$	75.66%	80.83%	82.72%	84.95%	77.84%
$\gamma = 1.0$	75.04%	80.95%	84.15%	84.31%	77.92%
$\gamma = 2.0$	73.37%	81.37%	85.26%	83.63%	78.93%

Bảng 3. 5. Ma trận khảo sát siêu tham số Focal Loss ($\gamma \times \alpha$) trên mô hình CNN-1D (Val F1 %).

$\gamma \backslash \alpha$	$\alpha=0.10$	$\alpha=0.25$	$\alpha=0.50$	$\alpha=0.75$	$\alpha=0.90$
$\gamma = 0.1$	0.00%	31.86%	0.00%	0.00%	0.00%
$\gamma = 0.2$	0.00%	32.30%	0.00%	0.00%	0.00%
$\gamma = 0.5$	0.00%	34.50%	0.00%	0.00%	0.00%
$\gamma = 1.0$	42.77%	57.84%	70.74%	71.51%	66.67%
$\gamma = 2.0$	42.53%	57.84%	69.69%	70.44%	66.26%

4 bảng trên là kết quả được đánh giá trên tập validation trong suốt 20 epochs huấn luyện (cố định Hidden Size = 64, Layers = 2, LR = 0.001).

3.2.2. Phân tích kết quả định lượng và luận điểm lựa chọn

Từ các kết quả đo đạc từ Bảng 3. 2 đến Bảng 3. 5, nhóm nghiên cứu rút ra các phân tích chuyên sâu về tác động của từng tham số đối với hiệu năng nhận diện:

- Vai trò của hệ số cân bằng α (Class Weighting): Thực nghiệm cho thấy dải giá trị $\alpha = 0.50$ liên tục tạo ra các cột hiệu năng áp đảo trên cả ba mô hình dạng chuỗi (BiGRU-Attention đạt 87.59%, GRU đạt 85.26%, LSTM đạt 85.17%). Việc thiết lập $\alpha = 0.50$ duy trì sự cân bằng lực kéo gradient giữa lớp dương tính (Fall) và âm tính (ADL), giúp mô hình tránh hiện tượng phạt tổn thất quá thiên lệch về một phía, từ đó đạt chỉ số F1-Score tối ưu hài hòa nhất;

- Ý nghĩa cơ chế của tham số γ (Focusing Parameter): Khi thiết lập $\gamma = 2.0$, thừa số $(1 - p_t)^2$ tạo ra lực triệt tiêu tổn thất đủ mạnh đối với các mẫu dễ phân loại ($p_t > 0.9$), buộc gradient tập trung tối đa vào việc xử lý các chuỗi hành vi khó ở vùng ranh giới (như cúi gập người đột ngột hoặc ngồi xuống nhanh). Cấu hình ($\alpha = 0.50, \gamma = 2.0$) giúp mô hình đề xuất BiGRU-Attention thiết lập đỉnh hiệu năng toàn cục (Global Peak) đạt 87.59%, cao nhất trong toàn bộ 100 cấu hình thử nghiệm;

- Hiện tượng suy biến của mô hình CNN-1D: Bảng 3. 5, ở các mức $\gamma \leq 0.5$, mạng CNN-1D bị sụt giảm F1-Score nghiêm trọng về mức 0% tại hầu hết các giá trị α . Nguyên nhân do CNN-1D thuần túy không trích xuất được phụ thuộc thời gian

dài; khi không có hệ số γ đủ lớn ($\gamma \geq 1.0$) để ép gradient học mẫu khó, mô hình bị lớp đa số ADL áp đảo hoàn toàn và dự đoán tất cả các mẫu về nhãn 0.

Tóm lại, bài khảo sát ma trận định lượng khẳng định bộ siêu tham số $\alpha = 0.50$ và $\gamma = 2.0$ trên kiến trúc BiGRU-Attention đại diện cho cấu hình tối ưu nhất. Lựa chọn này giúp hệ thống đạt hiệu năng đỉnh cao, xử lý triệt để bài toán mất cân bằng nhãn 3: 1 và đảm bảo tính tổng quát hóa bền vững khi đánh giá trên tập Test độc lập.

3.3. Đánh giá đóng góp của từng thành phần (Ablation Study)

Để chứng minh tính đúng đắn và xác định định lượng vai trò đóng góp của từng khối công nghệ trong hệ thống đề xuất, nhóm nghiên cứu thực hiện bài thử nghiệm bóc tách thành phần (Ablation Study).

Tất cả các biến thể mô hình được huấn luyện và đánh giá trên tập Validation trong suốt 20 epochs với cấu hình siêu tham số cố định: hidden_size = 64, num_layers = 2, learning_rate = 0.001, $\alpha = 0.50$ và $\gamma = 2.0$. Kết quả so sánh định lượng về độ chính xác và độ phức tạp tính toán được tổng hợp trong Bảng 3. 6:

Bảng 3. 6. Kết quả thực nghiệm nghiên cứu bóc tách thành phần (Ablation Study) trên tập Validation.

ST T	Biến thể Cấu hình Thử nghiệm	Accuracy (%)	Precision (%)	Recall (%)	F1-Score (%)	Parameters	FLOPs (M)	Tác động khi cắt bỏ / Thay thế
1	PROPOSED (BiGRU + Attention + Kinematics)	94.24	92.19	83.42	87.59	139,266	4.5100	Mô hình đề xuất đầy đủ (Baseline)
2	BiGRU (Bỏ Attention)	93.18	90.27	80.71	85.22	139,137	4.5059	F1 giảm -2.37%: Precision và Recall đều sụt giảm.

3	LSTM + Attention	93.31	89.15	82.6 1	85.7 5	185,602	6.000 9	F1 giảm -1.84%: Tồn thêm ~33.3% FLOPs và Params.
4	Vanilla LSTM (Bỏ Attention)	92.72	88.62	80.4 3	84.3 3	185,473	5.996 8	F1 giảm -3.26%: Tồn tài nguyên nhưng hiệu năng kém nhất.
5	Bỏ Kinematics (Chỉ Pose 34D)	93.91	91.32	82.8 8	86.8 9	113,154	3.674 4	F1 giảm -0.70%: Tiết kiệm ~18.5% FLOPs nhưng suy giảm hiệu năng.
6	Bỏ Focal Loss (Standard BCE)	93.84	91.54	82.3 4	86.7 0	139,266	4.510 0	F1 giảm -0.89%: Recall thấp hơn và tổng thể kém hiệu quả hơn Focal Loss.

Kết quả được đánh giá trên tập validation trong suốt 20 epochs huấn luyện (cố định $Hidden\ Size = 64$, $Layers = 2$, $LR = 0.001$, $\alpha = 0.50$ và $\gamma = 2.0$).

Từ Bảng 3. 6, tác động định lượng của từng thành phần kỹ thuật đối với hiệu năng hệ thống được tổng hợp như sau:

- Cơ chế Feed-Forward Soft Attention (Cấu hình 1 vs 2): Loại bỏ Attention khiến F1-Score sụt giảm mạnh nhất (-2.37% , từ 87.59% xuống 85.22%). Khối này chỉ bổ sung 129 tham số và 0.0041 MFLOPs, chứng minh hiệu quả lọc nhiễu và tập trung trọng số thời gian vượt trội với chi phí phần cứng gần như không đáng kể;

- Ưu thế BiGRU so với LSTM (Cấu hình 1 vs 3): Thay BiGRU bằng LSTM làm F1-Score giảm -1.84% (85.75%), đồng thời tiêu tốn thêm $> 33\%$ tài nguyên (185,602 tham số và 6.0009 MFLOPs). Kết quả khẳng định BiGRU chính xác và tối ưu hơn hẳn cho chuỗi khung xương ngắn 16 frames;

- Đặc trưng động học Kinematics (Cấu hình 1 vs 5): Bỏ Vận tốc và Gia tốc giúp tiết kiệm 18.53% FLOPs nhưng làm F1-Score giảm -0.70% và Recall sụt về 82.88% . Việc bổ sung Kinematics là sự đánh đổi hoàn toàn đáng giá để nắm bắt sự biến thiên năng lượng chuyển động đột ngột của sự cố té ngã;

- Hàm mất mát Focal Loss (Cấu hình 1 vs 6): Thay Focal Loss bằng BCE làm F1-Score giảm -0.89% và Recall giảm về 82.34% do bài toán mất cân bằng nhãn 3: 1 tái diễn, dù chi phí tính toán không đổi. Phép đối sánh chứng minh Focal Loss ép gradient học mẫu khó hiệu quả mà không phát sinh thêm chi phí phần cứng.

Tóm lại, cấu hình đề xuất (BiGRU + Attention + Kinematics + Focal Loss) đạt sự cân bằng hoàn hảo giữa độ chính xác nhận diện và chi phí tính toán, làm tiền đề vững chắc cho việc triển khai ứng dụng thời gian thực trên các thiết bị phần cứng biên (Edge AI).

3.4. Đánh giá hiệu năng trên tập Test độc lập và Ma trận nhầm lẫn

Sau khi hoàn tất giai đoạn tối ưu hóa siêu tham số và bóc tách thành phần, mô hình đề xuất BiGRU + Attention + Kinematics + Focal Loss được đưa vào đánh giá độc lập trên tập Test Set (1,514 mẫu, chiếm 15% tổng dữ liệu). Tập dữ liệu này hoàn toàn tách biệt và chưa từng xuất hiện trong quá trình huấn luyện hay tinh chỉnh tham số.

Để tối đa hóa khả năng phát hiện sự cố té ngã và cân bằng giữa các chỉ số, hệ thống áp dụng ngưỡng quyết định phân loại tối ưu theo chỉ số Youden Index

(Threshold ≈ 0.46).

3.4.1. Chỉ số hiệu năng tổng quát

Kết quả được định lượng trên tập Test độc lập được tổng hợp trong Bảng 3. 7:


Bảng 3. 7. Hiệu năng mô hình BiGRU-Attention trên tập Test độc lập.

Chỉ số đánh giá	Giá trị	Ý nghĩa thực tiễn trong ứng dụng giám sát
Accuracy	92.47%	Phân loại chính xác 92.47% tổng số chuỗi hành vi khung xương.
F1-Score	85.61%	Đạt mức cân bằng tối ưu giữa khả năng nhận diện sự cố và hạn chế báo động nhầm.
Recall (Fall)	91.62%	Nhận diện chính xác 91.62% các trường hợp té ngã thực tế; ưu tiên an toàn hàng đầu.
Precision	80.34%	Trong các cảnh báo phát ra, 80.34% phản ánh đúng sự cố té ngã thực tế.

Kết quả được huấn luyện tối đa 50 epochs, kết hợp Early Stopping (patience = 10).

3.4.2. Phân tích Ma trận nhầm lẫn (Confusion Matrix Analysis)

Chi tiết phân loại giữa nhãn thực tế (True Label) và nhãn dự đoán (Predicted Label) được thể hiện trực quan qua ma trận nhầm lẫn chuẩn hóa tại Hình 3. 1:



Hình 3. 1. Ma trận nhầm lẫn chuẩn hóa (Normalized Confusion Matrix) của mô hình BiGRU-Attention.

Từ ma trận nhầm lẫn chuẩn hóa (Hình 3. 1), hiệu năng nhận diện từng lớp hành vi được phân tích chi tiết:


- Lớp ADL (Sinh hoạt bình thường): Phân loại chính xác 93% (0.93) mẫu hành vi. Tỷ lệ báo động giả (False Alarm Rate / False Positive) chỉ chiếm 7% (0.07), giúp tránh gây phiền hà cho người giám hộ bởi các cảnh báo sai khi người cao tuổi sinh hoạt bình thường;

- Lớp Fall (Sự cố té ngã): Phát hiện chính xác 92% (0.92) các tình huống té ngã thực tế. Tỷ lệ bỏ sót sự cố (Miss Rate / False Negative) được kiểm soát ở mức rất thấp, chỉ 8% (0.08).

Kết quả trên chứng minh ngưỡng quyết định 0.46 giúp mô hình đáp ứng tốt tiêu chí ưu tiên Recall cho lớp té ngã, đảm bảo tính an toàn cao nhất cho hệ thống giám sát thời gian thực.

3.5. Phân tích quá trình huấn luyện (Loss & Accuracy History)

Diễn biến tối ưu hóa trọng số của mô hình BiGRU-Attention trong suốt 50 epochs huấn luyện được theo dõi qua hai biểu đồ lịch sử Loss và Accuracy tại Hình 3. 2:



Hình 3. 2. Biểu đồ lịch sử huấn luyện Loss (trái) và Accuracy (phải) của mô hình BiGRU-Attention.

3.5.1. Phân tích diễn biến Loss (Loss History)

Tốc độ hội tụ: Đường Train Loss (đường nét liền xanh) giảm nhanh và mượt mà từ 0.0460 (Epoch 1) xuống mức 0.0029 (Epoch 50). Điều này khẳng định thuật toán Adam kết hợp với cơ chế Attention giúp mạng cập nhật trọng số cực kỳ hiệu quả;

Độ ổn định và cực tiểu: Đường Val Loss (đường nét đứt cam) giảm sâu ở 10 epochs đầu và dao động ổn định trong vùng cực tiểu $[0.022 - 0.033]$, đạt đáy 0.0216 tại Epoch 32;

Kiểm soát Quá khớp (Overfitting): Mặc dù Train Loss tiếp tục giảm nhẹ ở các epoch cuối, Val Loss không bị bùng nổ mà duy trì biên độ đi ngang, chứng minh các kỹ thuật Dropout, Regularization và Focal Loss đã kiểm soát quá khớp rất tốt.

3.5.2. Phân tích diễn biến Độ chính xác (Accuracy History)

Tập huấn luyện (Train Set): Train Accuracy bứt phá mạnh mẽ từ 80.1% ở Epoch 1 lên 98.3% ở Epoch 50 (đạt đỉnh 98.9% ở Epoch 47 và 49), cho thấy khả năng học đặc trưng chuỗi động học vượt trội;


Tập kiểm thử nội bộ (Validation Set): Val Accuracy vượt mốc 91% chỉ sau 10 epochs đầu tiên và duy trì ổn định trong dải 92.5% – 95.2% cho đến cuối quá trình;

Khoảng cách độ chính xác: Chênh lệch giữa Train Accuracy và Val Accuracy duy trì ở mức nhỏ ($\sim 3.4\%$). Sự biến động phẳng ở các epoch cuối khẳng định mô hình đạt độ bền vững tối đa.

Trạng thái trọng số tối ưu nhất của mô hình được điểm kiểm soát (Checkpoint) tự động lưu trữ tại Epoch 46, thời điểm đạt hiệu năng đỉnh trên tập Validation với Val F1 đạt 90.1%, Val Recall đạt 88.6% và Val Accuracy đạt 95.2%. Bộ trọng số này chính thức được đóng gói để đánh giá độc lập trên tập Test và tích hợp vào ứng dụng phần mềm.

3.6. Giao diện người dùng

Hệ thống được tích hợp giao diện điều khiển dạng Dashboard trên nền tảng Django framework, kết hợp xử lý kịch bản phía Client bằng Vanilla JavaScript và HTML5 Canvas API. Giao diện đảm bảo tính phản hồi nhanh (Low Latency) và hỗ trợ theo dõi đa đối tượng thời gian thực (Multi-Person Tracking), được thể hiện trực quan trong Hình 3. 3 dưới đây.



Hình 3. 3. Giao diện Dashboard giám sát thời gian thực khi hệ thống phát hiện sự cố té ngã.

3.6.1. Kiến trúc và Nguyên lý vận hành Client-Server

Giao diện vận hành theo cơ chế bất đồng bộ truyền nhận luồng khung hình (Asynchronous Frame Streaming):

- Phía Client: Trích xuất khung hình từ Webcam hoặc video tải lên, nén JPEG (chất lượng 0.72) và gửi về API /api/predict/ qua FormData kèm session_id độc lập.
- Phía Server: Xử lý luồng ảnh qua YOLOv8n-Pose và BiGRU-Attention, trả về cấu trúc JSON chứa tọa độ khung xương, nhãn trạng thái và xác suất té ngã;
- Điều phối tần số quét (Adaptive Dynamic Schedule): Tự động điều chỉnh tốc độ gửi khung hình theo thời gian xử lý thực tế của Server (ngưỡng 10 – 30 FPS), tránh gây nghẽn hàng đợi mạng.

3.6.2. Các khối chức năng chính trên Dashboard

Giao diện được phân chia thành 4 khối chức năng chuyên biệt:

- Khối điều khiển nguồn dữ liệu (Media Source Control): Hỗ trợ bật Webcam trực tiếp, tải tệp video thực nghiệm (MP4/WebM) và đặt lại phiên làm việc;
- Khối hiển thị luồng Video & Canvas đa lớp: Tích hợp lớp phủ Canvas trong suốt đè lên khung hình video; tự động kích hoạt hiệu ứng viền chớp đỏ khi phát hiện té ngã;
- Khối thẻ trạng thái & Chỉ số vận hành: Thanh tiến trình hiển thị xác suất ngã trực quan kèm vạch ngưỡng Youden Index (45.77%);

4. ĐÁNH GIÁ TÁC ĐỘNG VÀ ĐỊNH HƯỚNG PHÁT TRIỂN

Chương này tổng kết và đánh giá toàn diện hiệu năng của hệ thống sau quá trình nghiên cứu, xây dựng và thực nghiệm. Trên cơ sở các kết quả định lượng đạt được, chương phân tích sâu các giá trị thực tiễn đối với bài toán giám sát an toàn y tế, đồng thời thẳng thắn chỉ ra các hạn chế kỹ thuật hiện hữu và đề xuất lộ trình hoàn thiện hệ thống trong tương lai.

4.1. Kết quả đạt được và Giá trị của ứng dụng

4.1.1. Kết quả đạt được

Sau quá trình nghiên cứu và thực nghiệm, đề tài đã hoàn thiện trọn vẹn hệ thống phát hiện té ngã người cao tuổi thời gian thực với các thành tựu kỹ thuật cốt lõi:

- Xây dựng luồng xử lý tự động khép kín (End-to-End Pipeline): Hoàn thiện quy trình công nghệ chuẩn hóa từ luồng video thô đầu vào → trích xuất tư thế YOLOv8n-Pose → chuẩn hóa không gian → biến đổi 102 chiều đặc trưng động học → dự đoán BiGRU-Attention → hiển thị trực quan hóa và phát tín hiệu cảnh báo trên giao diện Dashboard;

- Tạo lập tập dữ liệu khung xương chuẩn hóa: Trích xuất và đóng gói thành công 10.091 mẫu chuỗi thời gian (16 frames/cửa sổ, stride = 4) từ bộ dữ liệu chuẩn IMVIA Le2i Fall Detection Dataset;

- Mô hình hóa và Tối ưu hóa đạt hiệu năng cao: Huấn luyện thành công mạng hồi quy hai chiều BiGRU kết hợp Feed-Forward Soft Attention, tích hợp hàm mất mát Focal Loss ($\alpha = 0.50, \gamma = 2.0$) và Skeleton Jittering, đạt Accuracy 92.47%, Recall (Fall) 91.62% và F1-Score 85.61% trên tập Test độc lập;

- Thực nghiệm kiểm thử toàn diện: Thực hiện đầy đủ các bài đánh giá định lượng khoa học bao gồm 5-Fold Cross Validation, Grid Search siêu tham số, khảo sát ma trận Focal Loss (5×5), nghiên cứu bóc tách (Ablation Study) và ma trận nhầm lẫn.

4.1.2. Giá trị ứng dụng của hệ thống

Giải pháp mang lại nhiều giá trị thực tiễn nổi bật trong bài toán giám sát an toàn cho người cao tuổi:

- Bảo vệ quyền riêng tư tuyệt đối (Privacy-Preserving): Hệ thống chỉ trích

xuất và lưu trữ ma trận tọa độ khung xương (17 keypoints) thay vì truyền tải hình ảnh RGB thô, triệt tiêu rủi ro lộ thông tin cá nhân nhạy cảm;

- Khai thác chuyên sâu động lực học chuyển động: Việc kết hợp các thành phần Vị trí, Vận tốc và Gia tốc (102 đặc trưng) giúp mô hình đánh giá chính xác biến thiên năng lượng của tư thế;

- Tối ưu hóa tài nguyên phần cứng (Edge AI Friendly): Với dung lượng chỉ 139.266 tham số và chi phí tính toán 4.51 MFLOPs, kiến trúc đảm bảo khả năng vận hành thời gian thực mượt mà với độ trễ thấp trên thiết bị nhúng và máy tính biên.

4.2. Hạn chế của đề tài

Bên cạnh những kết quả tích cực, hệ thống vẫn tồn tại một số hạn chế kỹ thuật cần khắc phục trước khi triển khai thực địa quy mô lớn:

- Hạn chế về tính bao quát của dữ liệu: Bộ dữ liệu IMVIA Le2i chủ yếu được thu thập trong điều kiện phòng thực nghiệm có kiểm soát, chưa phản ánh đầy đủ mọi biến thể môi trường thực tế như điều kiện ánh sáng cực đoan, góc nhìn camera bị nghiêng hoặc các chướng ngại vật phức tạp;

- Độ nhạy của khâu trích xuất tư thế: Ở các tình huống góc quay từ trên cao (Top-down view) hoặc đối tượng bị che khuất một phần cơ thể (Occlusion), mô hình YOLOv8n-Pose có thể bị suy giảm độ chính xác định vị khớp, từ đó dẫn đến sai số lan truyền sang mô hình phân loại chuỗi;

- Hạn chế về thử nghiệm triển khai thực địa: Đề tài hiện mới đánh giá ở cấp độ cửa sổ chuỗi thời gian (16 frames) trong phạm vi nghiên cứu, chưa qua kiểm thử thực địa quy mô lớn trên luồng camera trực tiếp tại các hộ gia đình, bệnh viện hay viện dưỡng lão.

4.3. Hướng phát triển trong tương lai

Để hoàn thiện và nâng cao tính thực tiễn của hệ thống, lộ trình phát triển tiếp theo tập trung vào các định hướng trọng tâm:

- Đa dạng hóa dữ liệu và Khung xương 3D: Bổ sung các bộ dữ liệu đa góc nhìn (Multi-view), mô phỏng tình huống che khuất và nghiên cứu trích xuất tọa độ khung xương 3D để tăng độ bền vững không gian;

- Cải thiện thuật toán và Hậu xử lý chuỗi: Tích hợp các kỹ thuật hậu xử lý theo thời gian (Temporal Post-processing) như bỏ phiếu theo thời gian (Temporal

Voting) và ngưỡng quyết định động (Dynamic Threshold) trên luồng video liên tục nhằm triệt tiêu báo động giả ở các hành vi ranh giới;

- Tăng tốc suy luận và đóng gói nhúng: Ứng dụng các công cụ tối ưu hóa như ONNX Runtime và TensorRT để nén mô hình, giảm thiểu tối đa độ trễ (Latency) và gia tăng tốc độ xử lý khung hình (FPS) trên các vi xử lý biên tiết kiệm năng lượng;

- Mở rộng tính năng cảnh báo thông minh: Tích hợp mô-đun cảnh báo tức thời qua ứng dụng di động, gửi tin nhắn khẩn cấp hoặc chuông báo tự động tới người giám hộ và cơ sở y tế khi phát hiện sự cố.

KẾT LUẬN

Đề tài “**HỆ THỐNG PHÁT HIỆN TẾ NGÃ CHO NGƯỜI GIÀ**” đã xây dựng và thực nghiệm hoàn chỉnh quy trình phát hiện hành vi té ngã theo thời gian thực từ dữ liệu video dựa trên biểu diễn khung xương, đáp ứng được khả năng bảo vệ quyền riêng tư cá nhân.

Hệ thống đã chuẩn hóa và đóng gói thành công 10.091 mẫu chuỗi thời gian từ bộ dữ liệu IMVIA Lei2, kết hợp không gian tọa độ 17 điểm khớp với các đạo hàm vận tốc và gia tốc để hình thành vector đặc trưng động học 102 chiều cho mỗi khung hình. Kiến trúc đề xuất BiGRU tích hợp cơ chế Feed-Forward Soft Attention, kết hợp với hàm mất mát Focal Loss và kỹ thuật Skeleton Jittering, đã xử lý hiệu quả bài toán mất cân bằng lớp. Trên tập test độc lập, mô hình đã đạt được độ chính xác Accuracy 92.47%, F1-Score 85.61% và chỉ số Recall cho lớp té ngã đạt 91.62%. Với quy mô 139.266 tham số và chi phí tính toán 4.51 MFLOPs cho mỗi cửa sổ 16 khung hình, mô hình được tích hợp hoàn chỉnh vào ứng dụng Web Dashboard trên nền tảng Django, đảm bảo khả năng giám sát và cảnh báo thời gian thực.

Mặc dù hệ thống đạt độ ổn định cao trong các kịch bản thực nghiệm, bài toán nhận diện khi đối tượng bị che khuất hoặc thay đổi góc quay phức tạp vẫn là những hạn chế kỹ thuật cần hoàn thiện. Các định hướng tiếp theo tập trung vào việc mở rộng dữ liệu khung xương 3D, tích hợp thuật toán hậu xử lý chuỗi và tối ưu hóa mô hình TensorRT để triển khai trên các thiết bị tính toán biên trong môi trường thực tế.

DANH MỤC THAM KHẢO

- [1] Moreland, B. a. Kakara, R. a. Henry, and Aim, "Trends in Nonfatal Falls and Fall-Related Injuries Among Adults Aged," MMWR. Morbidity and Mortality Weekly Report, vol. 69, pp. 875--881, 2020. [Online]. Available: <https://www.cdc.gov/mmwr/volumes/69/wr/mm6927a5.htm>.
- [2] V. T. Ha et al., "Prevalence and Factors Associated with Falls among Older Outpatients," (in eng), Int J Environ Res Public Health, vol. 18, no. 8, Apr 12 2021, doi: 10.3390/ijerph18084041.
- [3] R. Igual, C. Medrano, and I. Plaza, "Challenges, issues and trends in fall detection systems," BioMedical Engineering OnLine, vol. 12, no. 1, p. 66, 2013/07/06 2013, doi: 10.1186/1475-925X-12-66.
- [4] Tan-in, T. a. Tangsakul, S. a. Namburi, and Atchara, "Edge-Native Privacy-Preserving Fall Detection System Using Optimized Skeleton-Based Pose Estimation on NVIDIA Jetson," Department of Computer and Information Science, Faculty of Science and Engineering, Kasetsart University, 2026.
- [5] C.-l. Wang and J. Yan, "A Comprehensive Survey of RGB-Based and Skeleton-Based Human Action Recognition," IEEE Access, vol. 11, pp. 53880-53898, 2023.
- [6] W. Chen, Z. Jiang, H. Guo, and X. Ni, "Fall Detection Based on Key Points of Human-Skeleton Using OpenPose," Symmetry, vol. 12, no. 5, p. 744, 2020. [Online]. Available: <https://www.mdpi.com/2073-8994/12/5/744>.
- [7] M. Schuster and K. K. Paliwal, "Bidirectional recurrent neural networks," IEEE Transactions on Signal Processing, vol. 45, pp. 2673-2681, 12/01 1997, doi: 10.1109/78.650093.
- [8] C. R. a. D. P. W. Ellis, "Feed-Forward Networks with Attention Can Solve Some Long-Term Memory Problems," arXiv preprint arXiv:1512.08756, 2016. [Online]. Available: <https://arxiv.org/abs/1512.08756>.
- [9] K. Cho et al., "Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation," arXiv preprint arXiv:1406.107, pp. 1724-1734, 2014. [Online]. Available: <https://arxiv.org/abs/1406.1078>.

NHẬN XÉT VÀ ĐÁNH GIÁ CỦA CÁC THÀNH VIÊN

TÊN THÀNH VIÊN	NHẬN XÉT VÀ ĐÁNH GIÁ
Phạm Long Chúc	Hiểu rõ bài toán, làm việc trách nhiệm và đáp ứng tốt các yêu cầu kỹ thuật của đề tài. Đảm nhận xây dựng kiến trúc mô hình, triển khai kiểm thử 5-Fold Cross Validation và phân tích toàn diện các chỉ số đánh giá cho báo cáo.
Trần Thị Hảo	Cẩn thận, tỉ mỉ và có thái độ làm việc rất trách nhiệm, chín chu. Đảm nhận và thực hiện khâu bóc tách nhãn annotation, làm sạch và chuẩn hóa bộ dữ liệu IMVIA Le2i.
Nguyễn Xuân Linh	Tự giác, chủ động và phối hợp nhóm hiệu quả. Đảm nhận và xây dựng thành công Dashboard trên nền tảng Django, tối ưu hóa giao diện người dùng (UI/UX) và đóng góp tích cực vào việc thiết kế slide báo cáo dự án.
Trần Đức Mạnh	Hăng hái, chủ động và có tinh thần hỗ trợ cao. Hoàn thành tốt nhiệm vụ được giao về tìm phương án giải quyết bài toán, làm slide báo cáo.

NHẬN XÉT VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN HƯỚNG DẪN

DANH MỤC	ĐIỂM	NHẬN XÉT VÀ ĐÁNH GIÁ
Ý TƯỞNG	___/10	
ỨNG DỤNG	___/30	
KẾT QUẢ	___/30	
QUẢN LÝ DỰ ÁN	___/10	
THUYẾT TRÌNH & BÁO CÁO	___/20	
TỔNG ĐIỂM	___/100	